Makine Öğrenmesi ile Seyahat Memnuniyeti Tahmini

Melih Ali Çağman[1], Işıl Cemre Sağlam[2], Üçüncü Yazar[3]
[1,2,3] *Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye*
mali.cagman@gazi.edu.tr · icemre.saglam@gazi.edu.tr · 23181616026@gazi.edu.tr

ÖZET — Bu çalışmada UCI Machine Learning Repository'de yer alan ve TripAdvisor kullanıcılarının on farklı mekân kategorisine verdiği ortalama puanları içeren Travel Reviews veri seti (980 kullanıcı) üzerinde yedi sınıflandırma algoritması (Karar Ağacı, Rastgele Orman, Lojistik Regresyon, KNN, SVM, Naive Bayes ve Yapay Sinir Ağı) karşılaştırılmıştır. Hedef değişken, kullanıcının en yüksek puan verdiği kategori olarak tanımlanmıştır. Önceki çalışmalarda yalnızca doğruluk (accuracy) ile raporlanan sonuçlar; dengeli doğruluk, makro F1, MCC, Cohen kappa ve log-loss ile genişletilmiş, 5×3 tekrarlı katmanlı çapraz doğrulama ve Wilcoxon işaretli sıra testi ile istatistiksel olarak desteklenmiştir. Karar Ağacı ve Rastgele Orman %99,5 doğruluğa ulaşmış; ancak etiket girdilerin *argmax*'ı olduğundan, eğitimsiz bir kural da %100 doğruluk vermektedir. Bu nedenle etiket sızıntısından arınmış ek bir görev (Kategori 10 puanının medyan üstünde olup olmadığı) ile K-Means tabanlı kullanıcı segmentasyonu da incelenmiştir. Sızıntısız görevde Rastgele Orman 0,909 ROC-AUC değerine ulaşmıştır.

Anahtar Kelimeler: Makine öğrenmesi, seyahat hizmetleri, müşteri memnuniyeti, sınıf dengesizliği, etiket sızıntısı

Abstract — We compare seven classifiers on the UCI Travel Reviews dataset (980 TripAdvisor users, ten venue categories) using accuracy, balanced accuracy, macro-F1, MCC, Cohen's κ and log-loss under 5×3 repeated stratified cross-validation. Tree-based models reach 99.5% accuracy, yet a training-free *argmax* rule scores 100% because the label is derived from the inputs. We therefore add a leakage-free task (is the Category-10 rating above the median?), where Random Forest attains a ROC-AUC of 0.909, and a K-Means user segmentation.

1. Giriş

Çağımızda insanların deneyimlerini internet siteleri aracılığıyla paylaşması, seyahat ve turizm sektöründe önemli bir bilgi kaynağı olarak kullanılmaktadır [3]. TripAdvisor gibi çevrimiçi değerlendirme siteleri, kullanıcıların oteller, restoranlar ve tarihi mekânlar hakkında verdiği puanlar aracılığıyla diğer kullanıcılara yol gösterici niteliktedir. Bu puanların analizi; müşteri memnuniyetini ölçme, hizmet kalitesini artırma ve öneri sistemleri geliştirme açısından kritik bir rol oynar [6, 7].

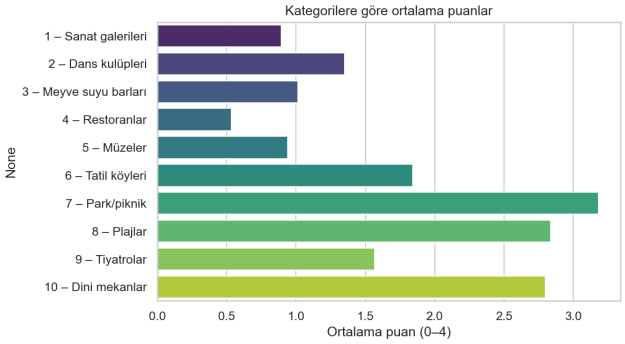
Bu çalışmanın amacı, kullanıcıların farklı kategorilerde verdiği puanlardan seyahat tercihlerine dair bir çıkarım yapmak ve yaygın makine öğrenmesi algoritmalarının bu görevdeki başarısını *doğru ölçütlerle* karşılaştırmaktır. Katkılarımız şunlardır: (i) yedi algoritmanın sekiz farklı ölçütle ve tekrarlı çapraz doğrulamayla karşılaştırılması; (ii) sınıf dengesizliğinin ve etiket sızıntısının sonuçlar üzerindeki etkisinin gösterilmesi; (iii) sızıntısız bir ikincil görev ve kümeleme analizi ile bulguların tamamlanması; (iv) tüm deneylerin açık kaynak olarak yeniden üretilebilir sunulması.

2. Materyal ve Yöntem

2.1. Veri Seti

Çalışmada UCI Machine Learning Repository'deki *Travel Reviews* veri seti kullanılmıştır [1, 2]. Veri seti, TripAdvisor kullanıcılarının on kategoriye verdiği ortalama puanları içerir; **980 kullanıcı** ve 10 sayısal özellikten oluşur, eksik değer yoktur. Puanlar 0–4 aralığındadır. Kategoriler sırasıyla sanat galerileri, dans kulüpleri, meyve suyu barları, restoranlar, müzeler, tatil köyleri, park/piknik alanları, plajlar, tiyatrolar ve dini mekânlardır (K1–K10).

Kategori 7 (park/piknik) puanı neredeyse sabittir (ortalama 3,18; standart sapma 0,008; aralık 3,16–3,21), bu da etiketin büyük ölçüde "başka bir kategori 3,18'in üzerine çıkıyor mu?" sorusuna indirgenmesine yol açar. Özellikler arası en yüksek mutlak korelasyon 0.75'dir.



Şekil 1. Kategorilere göre ortalama puanlar.

2.2. Hedef Değişken ve Sınıf Dağılımı

Hedef etiket, her kullanıcının en yüksek puan verdiği kategoridir (*idxmax*). Sonuçta dokuz sınıf oluşur; ancak dağılım son derece dengesizdir: Kategori 7 kullanıcıların %80.6'ini (790), Kategori 10 %16,4'ünü (161) oluştururken beş sınıfın yalnızca 1–2 örneği vardır. Bu nedenle "her zaman Kategori 7" diyen çoğunluk taban çizgisi bile hold-out kümesinde %76,5 doğruluk sağlar.

2.3. Ön İşleme ve Deney Tasarımı

Özellikler Min-Max normalizasyonu ile [0,1] aralığına ölçeklenmiştir [5]. Ölçekleyici, veri sızıntısını önlemek amacıyla her modelle birlikte bir *Pipeline* içinde yalnızca eğitim verisine uydurulmuştur. İki değerlendirme düzeni kullanılmıştır: (a) %80/%20 hold-out (rastgele tohum 42; önceki çalışmayla aynı bölme) ve (b) 5 kat × 3 tekrar katmanlı çapraz doğrulama (CV). KNN için komşu sayısı k, test kümesi yerine yalnızca eğitim kümesi üzerindeki 5 katlı CV ile seçilmiştir (k = 6); önceki çalışmada k'nın test doğruluğuna göre seçilmesi iyimser bir sapma doğuruyordu.

2.4. Algoritmalar

Temel kavramlar için [9]'a bakılabilir. **Karar Ağacı** veriyi özellik eşiklerine göre özyinelemeli bölerek yorumlanabilir kurallar üretir. **Rastgele Orman** [10], bootstrap örneklemeleri ve rastgele özellik alt kümeleriyle eğitilmiş ağaçların oy çokluğunu alır. **Lojistik Regresyon** çok sınıflı softmax ile doğrusal karar sınırı kurar. **KNN** en yakın k komşunun çoğunluk oyuna göre karar verir. **SVM** [8] RBF çekirdeğiyle

maksimum marjinli bir ayırıcı bulur. **Naive Bayes** (Gauss) özelliklerin koşullu bağımsızlığını varsayar. **Yapay Sinir Ağı** (MLP; 64–32 gizli nöron, ReLU, Adam, 2000 yineleme) doğrusal olmayan ilişkileri öğrenir. Tüm modeller scikit-learn [11] ile gerçeklenmiştir.

2.5. Değerlendirme Ölçütleri

Doğruluk dengesiz veride yanıltıcı olabileceğinden şu ölçütler birlikte raporlanmıştır: **dengeli doğruluk** (sınıf bazlı duyarlılıkların ortalaması), **makro kesinlik/duyarlılık/F1** (sınıflara eşit ağırlık), **ağırlıklı F1**, **Matthews korelasyon katsayısı (MCC)** [12], **Cohen kappa** [13] ve olasılık kalitesi için **log-loss**. İkili görevde ayrıca **ROC-AUC**, **PR-AUC** ve **Brier skoru**, regresyonda **MAE, RMSE ve R^2**, kümelemede **Silhouette** [14], **Davies-Bouldin** ve **Calinski-Harabasz** indeksleri kullanılmıştır. Modeller arası farkların anlamlılığı CV doğruluklarında eşleştirilmiş Wilcoxon işaretli sıra testiyle sınanmıştır [15].

3. Literatür Taraması

Öneri sistemleri, kullanıcı tercihlerine uygun içerik sunarak bilgi aşırı yüklenmesini azaltır ve seyahat gibi tercihe dayalı alanlarda özellikle önemlidir. Adomavicius ve Tuzhilin [6], içerik tabanlı, işbirlikçi ve hibrit yaklaşımların avantaj ve sınırlılıklarını kapsamlı biçimde incelemiştir. Ricci vd. [7] ise öneri sistemlerinin kuramsal temellerini, algoritmalarını ve turizm dâhil uygulama alanlarını ele alan kapsamlı bir başvuru kaynağı sunar. Veri setinin kaynak çalışması, aynı verinin sosyal medya ve turizm alanında bölümlemeli kümeleme algoritmalarıyla incelenmesini önermiştir [2]. Bu çalışma ise aynı veriyi denetimli öğrenme ve ölçüt çeşitliliği açısından ele alarak literatürü tamamlamaktadır.

4. Bulgular

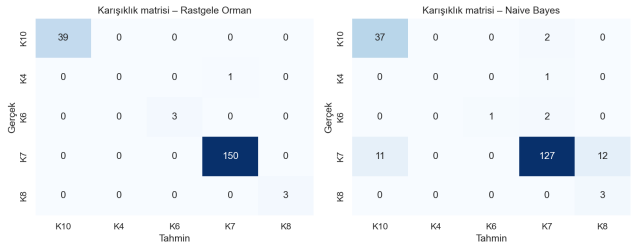
4.1. Orijinal Görev: Hold-out Sonuçları

Tablo 1. Hold-out (test n=196) sonuçları; en iyi değerler kalın.

Model	Doğr.	Den. Doğr.	Makro F1	MCC	Kappa
Taban çizgisi	0.7653	0.2000	0.1734	0.0000	0.0000
Karar Ağacı	**0.9949**	**0.8000**	**0.7993**	**0.9863**	**0.9862**
Rastgele Orman	**0.9949**	**0.8000**	**0.7993**	**0.9863**	**0.9862**
Lojistik Regresyon	0.9286	0.3679	0.3718	0.7983	0.7855
KNN	0.9133	0.4330	0.4610	0.7575	0.7551
SVM (RBF)	0.9541	0.4589	0.4865	0.8731	0.8703
Naive Bayes	0.8571	0.6257	0.5169	0.6880	0.6713
Yapay Sinir Ağı (MLP)	0.9745	0.5987	0.5967	0.9306	0.9297

Karar Ağacı ve Rastgele Orman %99,49 doğruluk (196 test örneğinden yalnızca 1 hata) ve 0,986 MCC ile en iyi sonucu vermiştir. Naive Bayes doğrulukta en düşük (%85,7) olsa da dengeli doğrulukta (0,626) KNN (0,433), SVM (0,459) ve Lojistik Regresyon'un (0,368) önündedir; çünkü nadir sınıfları çoğunluk sınıfına kıyasla daha sık yakalar. Yapay Sinir Ağı %97,4 doğruluk ve 0,597 makro F1 ile ağaç tabanlı olmayan modellerin en iyisidir. Önceki çalışmada %89 bildirilen değerin aksine, Min-Max ölçekli girdilerle MLP bu görevde belirgin biçimde daha yüksek sonuç vermiştir.

Önceki çalışmanın kodunda ölçeklenmiş verinin yalnızca KNN'de kullanıldığı, diğer modellerin ham veriyle eğitildiği görülmüştür. Ham veriyle Lojistik Regresyon 0.9490, ölçekli veriyle %92,86 doğruluk vermektedir; [0,1] ölçeğinde varsayılan L2 düzenlileştirme etkin biçimde güçlendiğinden bu düşüş beklenir. Raporlanan rakamlar bu düzenlemeden etkilenmektedir.



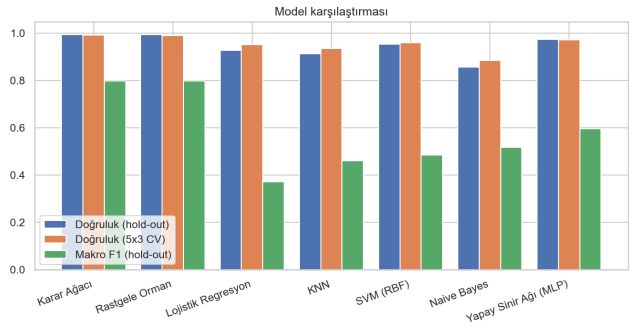
Şekil 2. Rastgele Orman ve Naive Bayes karışıklık matrisleri.

4.2. Tekrarlı Çapraz Doğrulama

Tablo 2. 5×3 katmanlı CV (ortalama ± std).

Model	Doğruluk	Den. Doğr.	Makro F1
Karar Ağacı	0.9925 ± 0.0049	0.8271 ± 0.1200	0.8147 ± 0.1397
Rastgele Orman	0.9908 ± 0.0042	0.7529 ± 0.0540	0.7559 ± 0.0509
Yapay Sinir Ağı (MLP)	0.9731 ± 0.0086	0.5765 ± 0.0775	0.5711 ± 0.0791
SVM (RBF)	0.9602 ± 0.0097	0.4394 ± 0.0578	0.4571 ± 0.0706
Lojistik Regresyon	0.9520 ± 0.0052	0.3674 ± 0.0264	0.3690 ± 0.0275
KNN	0.9364 ± 0.0153	0.4206 ± 0.0539	0.4368 ± 0.0665
Naive Bayes	0.8854 ± 0.0224	0.5882 ± 0.1011	0.4572 ± 0.0726

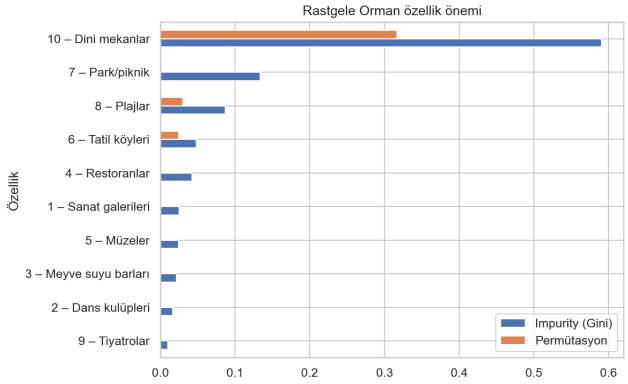
Sıralama hold-out ile tutarlıdır. Karar Ağacı (0,9925) ve Rastgele Orman (0,9908) arasındaki fark anlamlı değildir (Wilcoxon $p = 0.28$); buna karşılık Karar Ağacı'nın Lojistik Regresyon ve Naive Bayes'ten üstünlüğü anlamlıdır ($p < 0,001$). Makro F1'in standart sapması Karar Ağacı için 0,14 gibi yüksektir; çünkü tek örnekli sınıflar kat bazında rastgele eğitim ya da test kümesine düşer. Dolayısıyla tek bir hold-out bölmesindeki ince sıralama farkları güvenilir kabul edilmemelidir.



Şekil 3. Modellerin doğruluk ve makro F1 karşılaştırması.

4.3. Özellik Önemi

Rastgele Orman'da Gini önemi Kategori 10 için 0.59, Kategori 7 için 0.13 ve Kategori 8 için 0.09'dir. Permütasyon önemi de Kategori 10'u (0.317) açık farkla öne çıkarır; ardından Kategori 8 (0.030) ve Kategori 6 (0.024) gelir. Kategori 7'nin Gini önemine karşın permütasyon önemi ihmal edilebilirdir: değeri neredeyse sabit olduğundan bölme eşiklerinde sık kullanılsa da tahmine katkısı yoktur. Bu, Gini tabanlı önemin sabite yakın özelliklerde yanıltıcı olabileceğini gösterir [4].



Şekil 4. Gini ve permütasyon özellik önemi.

4.4. Etiket Sızıntısı

Etiket, girdilerin *argmax*'ı olduğundan eğitim gerektirmeyen "en yüksek puanlı kategoriyi seç" kuralı test kümesinde %100 doğruluk elde eder. Başka bir deyişle %99,5'lik ağaç tabanlı başarı, modelin gizli bir örüntüyü keşfetmesinden çok, kasıtlı olarak tanımlanmış bir kuralı yaklaşıklamasını yansıtır. Bu nedenle bu görevdeki yüksek doğruluk, gerçek dünyadaki tahmin gücü için kanıt olarak yorumlanmamalıdır.

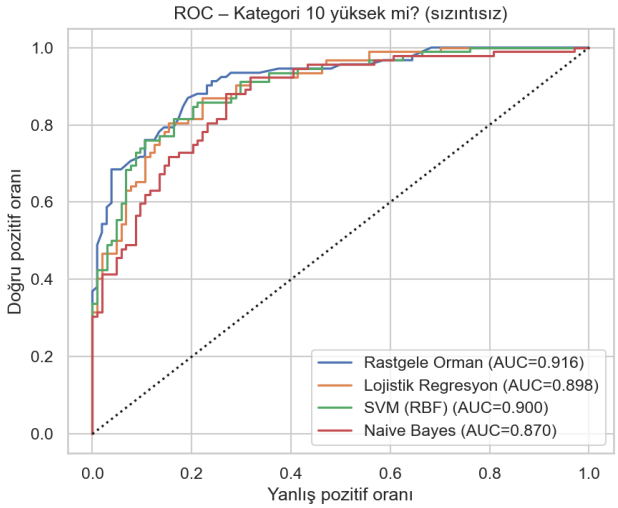
4.5. Sızıntısız Görev: Kategori 10 Puanı

Kategori 10 hedef alınmış, diğer dokuz kategori girdi olarak kullanılmıştır. Hedef, puanın medyanın (2.78) üzerinde olmasıdır (pozitif oran %46.8). Sonuçlar Tablo 3'te verilmiştir.

Tablo 3. Sızıntısız ikili görev (5×3 CV). AUC: ROC-AUC, AP: PR-AUC (ortalama kesinlik).

Model	Doğr.	F1	AUC	AP	MCC	Brier
Rastgele Orman	**0.813**	**0.794**	**0.909**	**0.904**	**0.625**	**0.123**
MLP	0.804	0.790	0.896	0.893	0.609	0.135
SVM (RBF)	0.797	0.786	0.895	0.892	0.594	0.133
Lojistik Regresyon	0.781	0.766	0.879	0.869	0.562	0.145
KNN	0.768	0.733	0.867	0.824	0.536	0.149
Naive Bayes	0.766	0.777	0.860	0.845	0.550	0.178
Karar Ağacı	0.762	0.744	0.760	0.676	0.522	0.238
Taban çizgisi	0.532	0.000	0.500	0.468	0.000	0.249

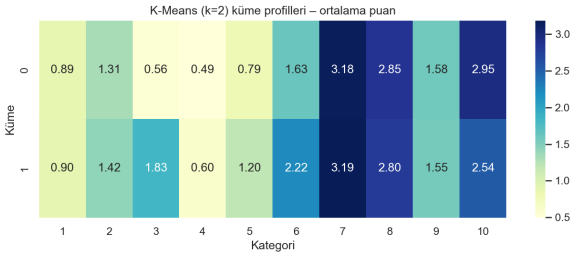
Rastgele Orman 0,909 ROC-AUC ve 0,625 MCC ile en iyi modeldir; taban çizgisi 0,5 AUC ve 0 MCC verir. Tek bir karar ağacı (AUC 0,760) aşırı uyum nedeniyle topluluk yöntemlerinin belirgin biçimde gerisindedir. Doğrusal modelin 0,880 AUC değeri kategoriler arasında büyük ölçüde doğrusal bir ilişki olduğunu, ormanın ek kazancı ise doğrusal olmayan etkileşimleri gösterir. Regresyon formülasyonunda Rastgele Orman R^2 = 0.70 (MAE 0.132) ve Ridge R^2 = 0.37 (MAE 0.201) elde etmiş, ortalama taban çizgisi (MAE 0.269) belirgin biçimde geçilmiştir. Bu, kullanıcıların dini mekânlara verdiği puanın diğer kategori puanlarından doğrusal olmayan biçimde tahmin edilebildiğini gösterir.



Şekil 5. Sızıntısız görevde ROC eğrileri.

4.6. Kullanıcı Segmentasyonu (K-Means)

Küme sayısı 2–8 arasında denenmiştir. Silhouette değeri k = 2'de en yüksektir (0.264); k = 3 için 0.190'e düşer. Davies-Bouldin (k = 2: 1.44) ve Calinski-Harabasz (393) indeksleri de k = 2'yi destekler. Silhouette değerinin 0,26 olması kümelerin belirgin ayrışmadığını, yani kullanıcı profillerinin sürekli bir spektrum oluşturduğunu gösterir. İki küme (628 ve 352 kullanıcı) esas olarak meyve suyu barı (K3: 0,56'ya karşı 1,83), müze (K5) ve tatil köyü (K6) puanları ile dini mekân puanında (K10: 2,95'e karşı 2,54) ayrışmaktadır.



Şekil 6. K-Means (k=2) küme profilleri.

5. Tartışma ve Sınırlılıklar

(1) **Etiket sızıntısı:** Asıl görev yapısal olarak kolaydır; model karşılaştırmaları bu nedenle algoritmaların üstünlüğünden çok karar sınırının geometrisine uyumunu ölçer. Ağaç tabanlı modeller eksen-hizalı eşikleri doğal olarak yakaladığından öne çıkar. (2) **Sınıf dengesizliği ve küçük örnek:** Beş sınıfın en çok iki örneği vardır; bu sınıflar için makro ölçütler yüksek varyans gösterir. Gelecek çalışmalarda SMOTE, sınıf ağırlıklandırma ya da sınıf birleştirme denenebilir. (3) **Veri doğası:** Veri, kullanıcı başına ortalama puanlardan oluşur; yorum metni, zaman veya konum bilgisi içermez. (4) **Hiperparametreler:** KNN dışındaki modellerde varsayılan hiperparametreler kullanılmıştır; kapsamlı bir ızgara araması sıralamayı değiştirebilir. (5) **Önceki çalışmayla farklar:** Önceki raporda veri seti 2048 satır olarak anılırken gerçek kayıt sayısı 980'dir; ayrıca ölçeklemenin tüm modellerde uygulandığı belirtilirken uygulamada yalnızca KNN için kullanılmıştır. Bu makalede her iki durum düzeltilmiştir.

6. Sonuç ve Öneriler

TripAdvisor Travel Reviews veri seti üzerinde yedi sınıflandırıcı; sekiz ölçüt ve tekrarlı çapraz doğrulama ile karşılaştırılmıştır. Karar Ağacı ve Rastgele Orman %99,5

civarında doğrulukla en başarılı modellerdir; ancak sonuç, etiketin girdilerin deterministik bir fonksiyonu olması nedeniyle ihtiyatla yorumlanmalıdır. Doğruluk yerine makro F1, dengeli doğruluk ve MCC kullanıldığında model sıralaması değişmekte (ör. Naive Bayes dengeli doğrulukta KNN ve SVM'i geçmekte), tek başına doğruluğun yanıltıcı olduğu görülmektedir. Sızıntısız ikincil görevde Rastgele Orman 0,909 ROC-AUC ile en iyi modeldir ve kategori puanlarının gerçek bir tahmin sinyali taşıdığını göstermektedir. Kümeleme analizi ise kullanıcı profillerinin belirgin ayrışmadığını ortaya koymuştur. Gelecek çalışmalarda yorum metinleri ve zaman bilgisiyle zenginleştirilmiş veri, sınıf dengeleme yöntemleri, hiperparametre optimizasyonu ve açıklanabilir yapay zekâ (SHAP) yaklaşımları önerilmektedir. Tüm kod ve sonuçlar https://github.com/MelihAliCagman/TravelReviews adresinde yeniden üretilebilir biçimde paylaşılmıştır.

KAYNAKÇA

[1] D. Dua and C. Graff, "UCI Machine Learning Repository," University of California, Irvine, 2019. [Online]. Available: https://archive.ics.uci.edu/ml/datasets/Travel+Reviews

[2] S. Renjith, A. Sreekumar, and M. Jathavedan, "Evaluation of partitioning clustering algorithms for processing social media data in tourism domain," in *Proc. IEEE Int. Conf. Recent Advances in Computational Systems (RAICS)*, 2018.

[3] TripAdvisor. [Online]. Available: https://www.tripadvisor.com

[4] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *J. Mach. Learn. Res.*, vol. 3, pp. 1157–1182, 2003.

[5] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2nd ed., O'Reilly Media, 2019.

[6] G. Adomavicius and A. Tuzhilin, "Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions," *IEEE Trans. Knowl. Data Eng.*, vol. 17, no. 6, pp. 734–749, Jun. 2005.

[7] F. Ricci, L. Rokach, and B. Shapira, Eds., *Recommender Systems Handbook*, 2nd ed., Springer, 2015.

[8] C. Cortes and V. Vapnik, "Support-vector networks," *Mach. Learn.*, vol. 20, no. 3, pp. 273–297, 1995.

[9] T. Mitchell, *Machine Learning*, McGraw-Hill, 1997.

[10] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.

[11] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[12] B. W. Matthews, "Comparison of the predicted and observed secondary structure of T4 phage lysozyme," *Biochim. Biophys. Acta*, vol. 405, no. 2, pp. 442–451, 1975.

[13] J. Cohen, "A coefficient of agreement for nominal scales," *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, 1960.

[14] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[15] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *J. Mach. Learn. Res.*, vol. 7, pp. 1–30, 2006.